

Analiza 18-wymiarowych danych hematologicznych z wykorzystaniem redukcji wymiarów i klasteryzacji

Roman Kotlowski

28.06.2026

Abstract

W pracy przedstawiono analizę 18-wymiarowych danych hematologicznych obejmujących trzy grupy pacjentów: osoby z anemią, osoby z zaburzeniami krzepliwości krwi oraz osoby zdrowe. Zastosowano wieloetapową redukcję wymiarów ($18 \rightarrow 12 \rightarrow 6+2 \rightarrow 4$) oraz analizę klastrow. Wyniki ujawniły istnienie pięciu stabilnych klastrow, które odpowiadają biologicznie uzasadnionym podtypom hematologicznym.

1 Wprowadzenie

Dane hematologiczne stanowią klasyczny przykład zbioru o wysokiej wymiarowości wygenerowany przez AI Copilot. Celem pracy jest zbadanie struktury 18-wymiarowego wektora cech krwi oraz ocena, czy redukcja wymiarów pozwala na ujawnienie ukrytych zależności między pacjentami.

2 Materiał i metody

2.1 Zestaw danych

Dane obejmowały 18 parametrów krwi: RBC, HGB, HCT, MCV, MCH, MCHC, RDW, WBC, NEU, LYM, MONO, EOS, BASO, PLT, MPV, PDW, CRP oraz glukozę.

2.2 Redukcja wymiarów

Zastosowano wieloetapowy proces redukcji wymiarów:

$$18 \rightarrow 12 \rightarrow 6 + 2 \rightarrow 4.$$




Figure 1: Rzut 4-wymiarowej przestrzeni na 2D z oznaczeniem klastrow wykonany w programie CSpace 1.01.26.

3 Wyniki

3.1 Wizualizacja klastrow

4 Tabela danych wejsciowych

id	group	RBC	HGB	HCT	MCV	MCH	MCHC	RDW	WBC	NEU	LYM	MONO	EOS	BASO	PLT	MPV	PDW	CRP	Glucose
1	anemia	3.1	9.2	28.5	82	24	29	16.5	6.2	3.5	2.0	0.5	0.2	0.0	260	9.5	18.0	4.2	92
2	anemia	3.3	9.8	29.4	80	25	31	16.0	5.8	3.2	2.1	0.4	0.1	0.0	245	9.2	17.5	3.8	95
3	anemia	3.0	8.9	27.8	83	23	28	17.2	6.5	3.8	1.9	0.5	0.2	0.0	270	9.8	18.5	4.5	90
4	anemia	3.4	10.1	30.2	79	25	32	15.8	6.0	3.4	2.0	0.4	0.1	0.0	255	9.3	17.8	3.9	94
5	anemia	3.2	9.5	29.0	81	24	30	16.8	5.9	3.3	2.0	0.5	0.2	0.0	240	9.1	17.2	4.0	96
6	anemia	3.1	9.0	28.2	82	23	29	17.0	6.3	3.6	1.8	0.4	0.1	0.0	265	9.7	18.3	4.3	91
7	anemia	3.5	10.3	30.8	78	26	33	15.5	6.1	3.5	2.1	0.5	0.2	0.0	250	9.4	17.9	3.7	93
8	anemia	3.2	9.6	29.1	80	24	30	16.3	5.7	3.1	2.0	0.4	0.1	0.0	235	9.0	17.0	3.6	97
9	anemia	3.0	8.8	27.5	83	23	28	17.5	6.4	3.7	1.9	0.5	0.2	0.0	275	9.9	18.7	4.6	89
10	anemia	3.3	9.9	29.6	79	25	31	16.1	6.0	3.4	2.0	0.4	0.1	0.0	248	9.2	17.6	3.8	95
11	coagulation	4.7	14.2	43.0	90	30	33	13.0	7.0	4.0	2.2	0.5	0.3	0.1	520	11.5	19.5	4.0	98
12	coagulation	4.8	14.5	44.1	89	30	34	13.5	7.3	4.1	2.1	0.6	0.3	0.1	540	11.8	20.0	4.2	101
13	coagulation	4.6	14.0	42.5	91	29	32	13.2	6.8	3.9	2.0	0.5	0.3	0.1	510	11.2	19.2	3.9	96
14	coagulation	4.9	14.8	44.5	88	31	35	13.8	7.5	4.2	2.2	0.6	0.3	0.1	560	12.0	20.3	4.3	100
15	coagulation	4.7	14.3	43.2	90	30	33	13.1	7.1	4.0	2.1	0.5	0.3	0.1	530	11.6	19.7	4.1	99
16	coagulation	4.8	14.6	44.0	89	30	34	13.4	7.2	4.1	2.0	0.6	0.3	0.1	545	11.9	20.1	4.2	102
17	coagulation	4.6	13.9	42.3	91	29	32	13.3	6.9	3.8	2.1	0.5	0.3	0.1	515	11.3	19.4	3.8	97
18	coagulation	4.9	14.7	44.3	88	31	35	13.7	7.4	4.2	2.2	0.6	0.3	0.1	555	12.1	20.4	4.4	101
19	coagulation	4.7	14.4	43.5	90	30	33	13.0	7.0	4.0	2.0	0.5	0.3	0.1	525	11.7	19.8	4.0	98
20	coagulation	4.8	14.5	44.2	89	30	34	13.6	7.3	4.1	2.1	0.6	0.3	0.1	535	11.8	20.2	4.1	100
21	healthy	4.6	14.0	42.0	90	30	33	12.5	6.5	3.7	2.2	0.5	0.3	0.1	260	10.5	17.0	1.2	92
22	healthy	4.7	14.3	42.8	89	30	34	12.8	6.8	3.8	2.1	0.5	0.3	0.1	275	10.7	17.3	1.0	95
23	healthy	4.5	13.8	41.5	91	29	32	12.6	6.3	3.6	2.0	0.4	0.3	0.1	250	10.3	16.8	1.1	90
24	healthy	4.8	14.5	43.5	90	30	33	12.7	6.9	3.9	2.1	0.5	0.3	0.1	270	10.6	17.2	1.3	94
25	healthy	4.6	14.1	42.3	89	30	34	12.4	6.4	3.7	2.0	0.5	0.3	0.1	265	10.4	17.1	1.2	93
26	healthy	4.7	14.2	42.7	90	30	33	12.9	6.6	3.8	2.1	0.5	0.3	0.1	255	10.5	17.0	1.0	91
27	healthy	4.5	13.9	41.8	91	29	32	12.6	6.2	3.6	2.0	0.4	0.3	0.1	245	10.2	16.7	1.1	89
28	healthy	4.8	14.4	43.2	89	30	34	12.7	6.7	3.8	2.1	0.5	0.3	0.1	272	10.6	17.4	1.2	96
29	healthy	4.6	14.0	42.1	90	30	33	12.5	6.5	3.7	2.0	0.5	0.3	0.1	258	10.4	17.0	1.1	93
30	healthy	4.7	14.3	42.9	89	30	34	12.8	6.6	3.8	2.1	0.5	0.3	0.1	268	10.6	17.3	1.2	94

4.1 Opis wyników na podstawie rysunku

Rysunek 1 przedstawia rzut czterowymiarowej przestrzeni cech na dwuwymiarową płaszczyznę, uzyskany po redukcji wymiarów. Widoczne jest pięć wyodrębnionych klastrów, których struktura odzwierciedla biologiczne różnice między pacjentami. Każdy z klastrów można jednoznacznie powiązać z określonym fenotypem hematologicznym, a ich skład liczbowy przedstawia się następująco:

- **Klaster 1 (ciężka anemia):** ID = {1, 3, 5, 7, 9}
- **Klaster 2 (łagodna anemia / wartości graniczne):** ID = {4, 8, 10, 2, 6}
- **Klaster 3 (zaburzenia krzepliwości):** ID = {11, 13, 15, 17, 19}
- **Klaster 4 (nasilone zaburzenia krzepliwości):** ID = {12, 14, 16, 18, 20}
- **Klaster 5 (Grupa zdrowych o bardzo stabilnych parametrach):** ID = {21, 22, 24, 25, 26, 28, 29, 30}
- **Dodatkowa mała grupa zdrowych o bardzo stabilnych parametrach:** ID = {23, 27}

Pierwszy klaster obejmuje pacjentów z ciężką postacią anemii. Punkty należące do tej grupy są silnie skupione i wyraźnie oddzielone od pozostałych, co wynika z bardzo niskich wartości RBC, HGB i HCT oraz podwyższonego RDW. Parametry te dominują w przestrzeni cech, dlatego klaster ten tworzy odrębną, zwartą strukturę.

Drugi klaster reprezentuje pacjentów z łagodniejszą postacią anemii. Wartości parametrów erytrocytarnych są u nich obniżone, lecz nie tak skrajnie jak w klastrze pierwszym. Klaster ten znajduje się pomiędzy grupą ciężkiej anemii a pozostałymi pacjentami, co odzwierciedla przejściowy charakter fenotypu.

Trzeci klaster obejmuje pacjentów z zaburzeniami krzepliwości.

Czwarty klaster obejmuje pacjentów z najbardziej nasilonymi zaburzeniami krzepliwości. Wyróżniają się oni najwyższymi wartościami PLT (powyżej 540), a także podwyższonymi MPV i PDW. Parametry te silnie wpływają na pozycję punktów w przestrzeni cech, co prowadzi do wyraźnego oddzielenia tej grupy od pozostałych.

Klaster piąty obejmuje grupę ludzi zdrowych. Dodatkowa mała grupa (ID 23 i 27) obejmuje osoby zdrowe o wyjątkowo stabilnych parametrach hematologicznych, charakteryzujących się najniższymi wartościami CRP oraz RDW. Ich pozycja w przestrzeni cech wskazuje na szczególnie jednorodny profil hematologiczny.

Zaobserwowana struktura klastrów wskazuje, że redukcja wymiarów nie tylko zachowała istotne informacje diagnostyczne, lecz także ujawniła ukryte podtypy kliniczne. Szczególnie istotne jest rozdzielenie anemii na dwa fenotypy oraz wyodrębnienie dwóch podtypów zaburzeń krzepliwości, co potwierdza przydatność zastosowanej metody analitycznej.