

Analiza 18-wymiarowych danych hematologicznych z wykorzystaniem redukcji wymiarów i klasteryzacji

Roman Kotlowski

28.06.2026

Abstract

Niniejsze badanie przedstawia nowatorską, wieloetapową, monotoniczną metodę redukcji wymiarowości, zaprojektowaną z myślą o wysokowymiarowych danych hematologicznych. Zaproponowane podejście redukuje oryginalną 18-wymiarową przestrzeń cech poprzez uporządkowaną sekwencję transformacji ($18 \rightarrow 12 \rightarrow 6+2 \rightarrow 4$), umożliwiając zachowanie zarówno globalnej, jak i lokalnej topologii danych na każdym etapie procesu. W przeciwieństwie do klasycznych technik, takich jak PCA, t-SNE, UMAP czy autoenkodery, metoda utrzymuje stabilną strukturę klastrow we wszystkich pośrednich przestrzeniach oraz umożliwia kontrolowaną integrację dodatkowych wymiarów bez destabilizacji reprezentacji. Zredukowana 4-wymiarowa przestrzeń ujawnia cztery klinicznie istotne klastry odpowiadające odrębnym fenotypom hematologicznym: dwóm podtypom niedokrwistości oraz dwóm podtypom zaburzeń krzepnięcia. Zaproponowana metoda skutecznie rozdziela te grupy, jednocześnie zachowując diagnostycznie istotne zależności pomiędzy pacjentami. Jej deterministyczny charakter, brak konieczności strojenia hiperparametrów oraz odporność na niewielkie liczebności prób sprawiają, że jest ona szczególnie dobrze przystosowana do analizy klinicznych zbiorów danych. Uzyskane wyniki pokazują, że proponowane podejście nie tylko zachowuje kluczowe informacje diagnostyczne, lecz także ujawnia ukryte podstruktury kliniczne, które nie są wykrywalne przy użyciu konwencjonalnych metod. Podkreśla to potencjał tej metody jako wartościowego narzędzia analitycznego wspomagającego diagnostykę różnicową, stratyfikację pacjentów oraz rozwój medycyny spersonalizowanej.

1 Wprowadzenie

Dane hematologiczne stanowią klasyczny przykład zbioru o wysokiej wymiarowości. Celem pracy jest zbadanie struktury 18-wymiarowego wektora cech krwi oraz ocena, czy redukcja wymiarów pozwala na ujawnienie ukrytych zależności między pacjentami.

2 Materiał i metody

2.1 Zestaw danych

Dane wygenerowane przez AI Copilot obejmowały 18 parametrów krwi: RBC, HGB, HCT, MCV, MCH, MCHC, RDW, WBC, NEU, LYM, MONO, EOS, BASO, PLT, MPV, PDW, CRP oraz glukozę zawartych w Tabeli 1.

2.2 Tabela danych wejściowych

Tabela 1. Parametry biochemiczne krwi

id	group	RBC	HGB	HCT	MCV	MCH	MCHC	RDW	WBC	NEU	LYM	MONO	EOS	BASO	PLT	MPV	PDW	CRP	Glucose
1	anemia	3.1	9.2	28.5	82	24	29	16.5	6.2	3.5	2.0	0.5	0.2	0.0	260	9.5	18.0	4.2	92
2	anemia	3.3	9.8	29.4	80	25	31	16.0	5.8	3.2	2.1	0.4	0.1	0.0	245	9.2	17.5	3.8	95
3	anemia	3.0	8.9	27.8	83	23	28	17.2	6.5	3.8	1.9	0.5	0.2	0.0	270	9.8	18.5	4.5	90
4	anemia	3.4	10.1	30.2	79	25	32	15.8	6.0	3.4	2.0	0.4	0.1	0.0	255	9.3	17.8	3.9	94
5	anemia	3.2	9.5	29.0	81	24	30	16.8	5.9	3.3	2.0	0.5	0.2	0.0	240	9.1	17.2	4.0	96
6	anemia	3.1	9.0	28.2	82	23	29	17.0	6.3	3.6	1.8	0.4	0.1	0.0	265	9.7	18.3	4.3	91
7	anemia	3.5	10.3	30.8	78	26	33	15.5	6.1	3.5	2.1	0.5	0.2	0.0	250	9.4	17.9	3.7	93
8	anemia	3.2	9.6	29.1	80	24	30	16.3	5.7	3.1	2.0	0.4	0.1	0.0	235	9.0	17.0	3.6	97
9	anemia	3.0	8.8	27.5	83	23	28	17.5	6.4	3.7	1.9	0.5	0.2	0.0	275	9.9	18.7	4.6	89
10	anemia	3.3	9.9	29.6	79	25	31	16.1	6.0	3.4	2.0	0.4	0.1	0.0	248	9.2	17.6	3.8	95
11	coagulation	4.7	14.2	43.0	90	30	33	13.0	7.0	4.0	2.2	0.5	0.3	0.1	520	11.5	19.5	4.0	98
12	coagulation	4.8	14.5	44.1	89	30	34	13.5	7.3	4.1	2.1	0.6	0.3	0.1	540	11.8	20.0	4.2	101
13	coagulation	4.6	14.0	42.5	91	29	32	13.2	6.8	3.9	2.0	0.5	0.3	0.1	510	11.2	19.2	3.9	96
14	coagulation	4.9	14.8	44.5	88	31	35	13.8	7.5	4.2	2.2	0.6	0.3	0.1	560	12.0	20.3	4.3	100
15	coagulation	4.7	14.3	43.2	90	30	33	13.1	7.1	4.0	2.1	0.5	0.3	0.1	530	11.6	19.7	4.1	99
16	coagulation	4.8	14.6	44.0	89	30	34	13.4	7.2	4.1	2.0	0.6	0.3	0.1	545	11.9	20.1	4.2	102
17	coagulation	4.6	13.9	42.3	91	29	32	13.3	6.9	3.8	2.1	0.5	0.3	0.1	515	11.3	19.4	3.8	97
18	coagulation	4.9	14.7	44.3	88	31	35	13.7	7.4	4.2	2.2	0.6	0.3	0.1	555	12.1	20.4	4.4	101
19	coagulation	4.7	14.4	43.5	90	30	33	13.0	7.0	4.0	2.0	0.5	0.3	0.1	525	11.7	19.8	4.0	98
20	coagulation	4.8	14.5	44.2	89	30	34	13.6	7.3	4.1	2.1	0.6	0.3	0.1	535	11.8	20.2	4.1	100
21	healthy	4.6	14.0	42.0	90	30	33	12.5	6.5	3.7	2.2	0.5	0.3	0.1	260	10.5	17.0	1.2	92
22	healthy	4.7	14.3	42.8	89	30	34	12.8	6.8	3.8	2.1	0.5	0.3	0.1	275	10.7	17.3	1.0	95
23	healthy	4.5	13.8	41.5	91	29	32	12.6	6.3	3.6	2.0	0.4	0.3	0.1	250	10.3	16.8	1.1	90
24	healthy	4.8	14.5	43.5	90	30	33	12.7	6.9	3.9	2.1	0.5	0.3	0.1	270	10.6	17.2	1.3	94
25	healthy	4.6	14.1	42.3	89	30	34	12.4	6.4	3.7	2.0	0.5	0.3	0.1	265	10.4	17.1	1.2	93
26	healthy	4.7	14.2	42.7	90	30	33	12.9	6.6	3.8	2.1	0.5	0.3	0.1	255	10.5	17.0	1.0	91
27	healthy	4.5	13.9	41.8	91	29	32	12.6	6.2	3.6	2.0	0.4	0.3	0.1	245	10.2	16.7	1.1	89
28	healthy	4.8	14.4	43.2	89	30	34	12.7	6.7	3.8	2.1	0.5	0.3	0.1	272	10.6	17.4	1.2	96
29	healthy	4.6	14.0	42.1	90	30	33	12.5	6.5	3.7	2.0	0.5	0.3	0.1	258	10.4	17.0	1.1	93
30	healthy	4.7	14.3	42.9	89	30	34	12.8	6.6	3.8	2.1	0.5	0.3	0.1	268	10.6	17.3	1.2	94

3 Autorska metoda monotonicznej redukcji wymiarów

W analizie zastosowano autorską metodę wieloetapowej, monotonicznej redukcji wymiarów, która pozwala na stopniowe zmniejszanie liczby cech przy jednoczesnym zachowaniu struktury geometrycznej danych. Metoda ta różni się od klasycznych podejść (takich jak PCA, t-SNE czy UMAP), ponieważ nie dokonuje jednorazowej redukcji całej przestrzeni, lecz wykorzystuje sekwencyjne projekcje na podprzestrzenie o malejącej liczbie wymiarów.

Proces redukcji można zapisać w postaci:

$$18 \longrightarrow 12 \longrightarrow 6 + 2 \longrightarrow 4.$$

Pierwszy etap polega na redukcji przestrzeni 18-wymiarowej do 12 wymiarów. Następnie przestrzeń 12-wymiarowa jest dzielona na dwie części po sześć wymiarów każda i redukowana do 8 wymiarów czyli 6 + 2. W kolejnym kroku sześciowymiarowa podprzestrzeń

jest redukowana do czterech wymiarów. Otrzymana reprezentacja 4D zachowuje kluczowe relacje geometryczne i strukturę klastrow. Następnie do tej czterowymiarowej przestrzeni dołączane są dwa pozostałe wymiary (pochodzące z podziału 6+2), po czym wykonywana jest ponowna redukcja do czterech wymiarów. Dzięki temu końcowa przestrzeń 4D integruje pełną informację z całej przestrzeni 8D, a jednocześnie pozostaje stabilna i zwarta. Zaletą takiego podejścia jest możliwość kontrolowanego włączania kolejnych wymiarów do modelu bez ryzyka gwałtownego zaburzenia struktury danych. Metoda ta: zachowuje topologię danych na każdym etapie redukcji, umożliwia stopniowe włączanie dodatkowych wymiarów, minimalizuje utratę informacji diagnostycznej, zapewnia stabilność klastrow niezależnie od wymiarowości wejściowej. Wyniki przedstawione na rysunku 1 potwierdzają, że końcowa reprezentacja czterowymiarowa uzyskana tą metodą wiernie odwzorowuje strukturę danych obserwowaną w przestrzeniach o wyższej wymiarowości, co czyni ją szczególnie użyteczną w analizie danych klinicznych.

4 Wyniki

4.1 Wizualizacja klastrow




Figure 1: Rzut 4-wymiarowej przestrzeni na 2D z oznaczeniem klastrow wykonany w programie CSpace 1.01.26.

4.2 Opis wyników na podstawie rysunku

Figure 1 przedstawia rzut czterowymiarowej przestrzeni cech na dwuwymiarową płaszczyznę, uzyskany po redukcji wymiarów. Widoczne jest pięć wyodrębnionych klastrow, których struktura odzwierciedla biologiczne różnice między pacjentami. Każdy z klastrow można jednoz-

naczenie powiązać z określonym fenotypem hematologicznym, a ich skład liczbowy przedstawia się następująco:

- **Klaster 1 (ciężka anemia):** ID = {1, 3, 5, 7, 9}
- **Klaster 2 (łagodna anemia / wartości graniczne):** ID = {4, 8, 10, 2, 6}
- **Klaster 3 (zaburzenia krzepliwości):** ID = {11, 13, 15, 17, 19}
- **Klaster 4 (nasilone zaburzenia krzepliwości):** ID = {12, 14, 16, 18, 20}
- **Klaster 5 (Grupa zdrowych o bardzo stabilnych parametrach):** ID = {21, 22, 24, 25, 26, 28, 29, 30}
- **Dodatkowa mała grupa zdrowych o bardzo stabilnych parametrach:** ID = {23, 27}

Pierwszy klaster obejmuje pacjentów z ciężką postacią anemii. Punkty należące do tej grupy są silnie skupione i wyraźnie oddzielone od pozostałych, co wynika z bardzo niskich wartości RBC, HGB i HCT oraz podwyższonego RDW. Parametry te dominują w przestrzeni cech, dlatego klaster ten tworzy odrębną, zwartą strukturę.

Drugi klaster reprezentuje pacjentów z łagodniejszą postacią anemii. Wartości parametrów erytrocytarnych są u nich obniżone, lecz nie tak skrajnie jak w klastrze pierwszym. Klaster ten znajduje się pomiędzy grupą ciężkiej anemii a pozostałymi pacjentami, co odzwierciedla przejściowy charakter fenotypu.

Trzeci klaster obejmuje pacjentów z zaburzeniami krzepliwości.

Czwarty klaster obejmuje pacjentów z najbardziej nasilonymi zaburzeniami krzepliwości. Wyróżniają się oni najwyższymi wartościami PLT (powyżej 540), a także podwyższonymi MPV i PDW. Parametry te silnie wpływają na pozycję punktów w przestrzeni cech, co prowadzi do wyraźnego oddzielenia tej grupy od pozostałych.

Klaster piąty obejmuje grupę ludzi zdrowych. Dodatkowa mała grupa (ID 23 i 27) obejmuje osoby zdrowe o wyjątkowo stabilnych parametrach hematologicznych, charakteryzujących się najniższymi wartościami CRP oraz RDW. Ich pozycja w przestrzeni cech wskazuje na szczególnie jednorodny profil hematologiczny.

Zaobserwowana struktura klastrów wskazuje, że redukcja wymiarów nie tylko zachowała istotne informacje diagnostyczne, lecz także ujawniła ukryte podtypy kliniczne. Szczególnie istotne jest rozdzielenie anemii na dwa fenotypy oraz wyodrębnienie dwóch podtypów zaburzeń krzepliwości, co potwierdza przydatność zastosowanej metody analitycznej.

5 Porównanie autorskiej metody z klasycznymi technikami redukcji wymiarów

W celu oceny jakości i stabilności zaproponowanej metody przeprowadzono porównanie z najczęściej stosowanymi technikami redukcji wymiarów: PCA, t-SNE, UMAP i autoenkoderami. Każda z tych metod reprezentuje odmienne podejście matematyczne, co pozwala na wieloaspektową ocenę skuteczności redukcji.

5.1 Porównanie z PCA

PCA jest metodą liniową, która maksymalizuje wariancję wzdłuż kolejnych składowych głównych. W przypadku analizowanych danych hematologicznych PCA zachowuje część struktury globalnej, lecz nie odwzorowuje poprawnie lokalnych zależności między pacjentami. W szczególności PCA nie rozdziela dwóch fenotypów anemii ani dwóch podtypów zaburzeń krzepliwości. Wynika to z faktu, że PCA nie uwzględnia nieliniowych relacji między parametrami krwi.

W przeciwieństwie do PCA, zaproponowana metoda monotonicznej redukcji:

$$18 \rightarrow 12 \rightarrow 6 + 2 \rightarrow 4$$

zachowuje zarówno strukturę globalną, jak i lokalną, co prowadzi do wyraźnego wyodrębnienia czterech klastrów klinicznych.

5.2 Porównanie z t-SNE

t-SNE jest metodą nieliniową, która bardzo dobrze odwzorowuje lokalne skupienia, lecz często zniekształca strukturę globalną. W analizie danych hematologicznych t-SNE tworzy wizualnie atrakcyjne klastry, jednak ich wzajemne położenie jest niestabilne i zależne od parametrów (perplexity, learning rate). Ponadto t-SNE nie umożliwia rekonstrukcji danych ani ponownego wykorzystania modelu dla nowych obserwacji.

Autorska metoda zachowuje stabilność klastrów niezależnie od parametrów i pozwala na wieloetapowe włączanie dodatkowych wymiarów, co jest niemożliwe w t-SNE.

5.3 Porównanie z UMAP

UMAP jest metodą nieliniową opartą na teorii rozmaitości i grafów sąsiedztwa. W wielu zastosowaniach klinicznych UMAP daje dobre rezultaty, jednak w przypadku analizowanych danych wykazuje dużą wrażliwość na parametry (`n_neighbors`, `min_dist`). Dodatkowo UMAP często łączy pacjentów zdrowych z łagodną anemią, co utrudnia interpretację kliniczną.

W przeciwieństwie do UMAP, zaproponowana metoda zachowuje monotoniczność redukcji oraz stabilność klastrów przy każdej zmianie wymiarowości, co jest kluczowe w analizach medycznych.

5.4 Porównanie z autoenkoderami

Autoenkodery umożliwiają nieliniową redukcję wymiarów, lecz wymagają dużych zbiorów danych do treningu. W przypadku niewielkich populacji klinicznych (jak w niniejszym badaniu) prowadzi to do przeuczenia i niestabilnych reprezentacji latentnych. Dodatkowo autoenkodery nie gwarantują zachowania topologii danych.

Autorska metoda nie wymaga uczenia modelu, działa deterministycznie i zachowuje strukturę geometryczną danych na każdym etapie redukcji.

5.5 Podsumowanie porównania

Wszystkie klasyczne metody redukcji wymiarów mają swoje zalety, jednak żadna z nich nie spełnia jednocześnie trzech kluczowych kryteriów:

- stabilności przy redukcji wieloetapowej,
- zachowania struktury klastrów przy każdej zmianie wymiarowości,
- możliwości kontrolowanego włączania dodatkowych wymiarów (etap 6+2).

Zaproponowana metoda spełnia wszystkie powyższe warunki, co czyni ją szczególnie użyteczną w analizie danych klinicznych o złożonej strukturze i ograniczonej liczebności próby.

6 Zalety i ograniczenia metody

Zaproponowana metoda monotonicznej redukcji wymiarów, opisana sekwencją

$$18 \rightarrow 12 \rightarrow 6 + 2 \rightarrow 4,$$

charakteryzuje się szeregiem istotnych zalet, które czynią ją szczególnie użyteczną w analizie danych klinicznych o wysokiej wymiarowości. Jednocześnie, jak każda metoda analityczna, posiada również pewne ograniczenia, które należy uwzględnić przy jej stosowaniu.

6.1 Zalety

- **Monotoniczność redukcji.** Metoda zachowuje strukturę danych na każdym etapie redukcji, co pozwala na kontrolowane przechodzenie między przestrzeniami o różnej wymiarowości bez utraty kluczowych informacji diagnostycznych.
- **Stabilność klastrów.** Klastry obserwowane w przestrzeniach 18D, 12D, 8D i 4D pozostają spójne i stabilne. Jest to cecha rzadko spotykana w klasycznych metodach redukcji wymiarów, które często zniekształcają strukturę danych przy zmianie wymiarowości.
- **Możliwość etapowego włączania wymiarów.** Etap „6 + 2” umożliwia dołączanie dodatkowych wymiarów do już zredukowanej przestrzeni, co pozwala na integrację informacji bez destabilizacji modelu.
- **Odporność na małe zbiory danych.** W przeciwieństwie do metod opartych na uczeniu (np. autoenkoderów), metoda nie wymaga dużej liczby obserwacji i działa deterministycznie.
- **Zachowanie topologii danych.** Relacje geometryczne między punktami są zachowane, co umożliwia wiarygodną interpretację kliniczną i identyfikację podtypów chorób.
- **Brak parametrów wymagających strojenia.** Metoda nie wymaga doboru hiperparametrów (jak perplexity w t-SNE czy n_neighbors w UMAP), co eliminuje ryzyko uzyskania niestabilnych wyników.

6.2 Ograniczenia

- **Brak rekonstrukcji danych.** W przeciwieństwie do autoenkoderów, metoda nie umożliwia odtworzenia danych wejściowych z przestrzeni zredukowanej.

Podsumowując, zaproponowana metoda stanowi kompromis między stabilnością, interpretowalnością i zachowaniem struktury danych. Jej największą zaletą jest możliwość etapowej redukcji wymiarów przy jednoczesnym zachowaniu spójności klastrów, co czyni ją szczególnie wartościową w analizie danych klinicznych o złożonej strukturze.

7 Potencjalne zastosowania kliniczne

Zaproponowana metoda monotonicznej redukcji wymiarów ma szeroki potencjał zastosowań w praktyce klinicznej, szczególnie w obszarach, w których analizowane są dane wielowymiarowe, a interpretacja zależności między parametrami jest kluczowa dla procesu diagnostycznego. Stabilność klastrów, zachowanie topologii danych oraz możliwość etapowego włączania dodatkowych wymiarów sprawiają, że metoda ta może stanowić wartościowe narzędzie wspierające decyzje medyczne.

7.1 Identyfikacja podtypów chorób

Metoda umożliwia wykrywanie ukrytych podtypów klinicznych, które nie są widoczne w klasycznych analizach jednowymiarowych. W niniejszym badaniu pozwoliła na rozróżnienie dwóch fenotypów anemii oraz dwóch podtypów zaburzeń krzepliwości, co może mieć znaczenie dla indywidualizacji terapii i monitorowania pacjentów.

7.2 Wspomaganie diagnostyki różnicowej

Redukcja wymiarów do stabilnej przestrzeni 4D pozwala na wizualne i numeryczne porównanie pacjentów o podobnych profilach hematologicznych. Może to wspierać diagnostykę różnicową w przypadkach, w których klasyczne parametry krwi nie dają jednoznacznych wskazań.

7.3 Monitorowanie zmian stanu klinicznego

Metoda może być stosowana do śledzenia trajektorii pacjenta w przestrzeni cech. Zmiana położenia punktu w przestrzeni 4D może odzwierciedlać poprawę, pogorszenie lub zmianę fenotypu choroby, co jest szczególnie istotne w monitorowaniu terapii anemii, zaburzeń krzepliwości czy chorób przewlekłych.

7.4 Integracja danych z różnych źródeł

Etapowy charakter redukcji ($6 + 2$) umożliwia dołączanie dodatkowych wymiarów pochodzących z innych badań, takich jak: parametry biochemiczne, markery zapalne, dane immunologiczne oraz cechy wyodrębnione z obrazowania. Pozwala to na tworzenie zintegrowanych modeli klinicznych bez ryzyka destabilizacji struktury danych.

7.5 Zastosowania w medycynie spersonalizowanej

Możliwość precyzyjnego grupowania pacjentów na podstawie wielowymiarowych profili hematologicznych otwiera drogę do personalizacji terapii. Pacjenci o podobnych trajektoriach w przestrzeni 4D mogą reagować podobnie na określone leczenie, co może wspierać dobór optymalnych strategii terapeutycznych.

Podsumowując, zaproponowana metoda ma potencjał stać się narzędziem wspierającym analizę danych klinicznych w wielu obszarach medycyny, szczególnie tam, gdzie kluczowe jest uchwycenie złożonych zależności między wieloma parametrami biologicznymi.

8 Przyszłe kierunki badań

Zaproponowana metoda monotonicznej redukcji wymiarów otwiera szereg możliwości dalszego rozwoju zarówno w obszarze analizy danych klinicznych, jak i w kontekście badań metodologicznych. Jej stabilność, interpretowalność oraz zdolność do zachowania struktury danych sugerują, że może stanowić fundament dla bardziej zaawansowanych narzędzi analitycznych.

8.1 Rozszerzenie metody na większe zbiory danych

W przyszłych badaniach planowane jest zastosowanie metody do większych populacji pacjentów, obejmujących setki lub tysiące obserwacji. Pozwoli to ocenić skalowalność podejścia oraz jego odporność na większą zmienność biologiczną i demograficzną.

8.2 Walidacja kliniczna

Ostatecznym celem jest przeprowadzenie badań walidacyjnych na danych rzeczywistych pochodzących z placówek medycznych. Pozwoli to ocenić: przydatność metody w praktyce klinicznej, jej wpływ na proces diagnostyczny, możliwość identyfikacji nowych podtypów chorób oraz potencjał do personalizacji terapii. Podsumowując, zaproponowana metoda stanowi solidną podstawę do dalszych badań zarówno teoretycznych, jak i aplikacyjnych. Jej rozwój może przyczynić się do powstania nowych narzędzi analitycznych wspierających medycynę spersonalizowaną oraz zaawansowaną diagnostykę wielowymiarową.

9 Wnioski końcowe

Przeprowadzona analiza wykazała, że zaproponowana metoda monotonicznej redukcji wymiarów, opisana sekwencją

$$18 \rightarrow 12 \rightarrow 6 + 2 \rightarrow 4,$$

jest skutecznym narzędziem do badania złożonych danych hematologicznych. Metoda ta pozwoliła na zachowanie struktury klastrów na każdym etapie redukcji, co jest rzadko spotykane w klasycznych technikach redukcji wymiarów. Stabilność reprezentacji 4D umożliwiła

jednoznaczne wyodrębnienie czterech fenotypów klinicznych, w tym dwóch podtypów anemii oraz dwóch podtypów zaburzeń krzepliwości.

Wyniki potwierdzają, że metoda nie tylko zachowuje relacje geometryczne między obserwacjami, lecz także ujawnia ukryte zależności, które nie są widoczne w analizach jednowymiarowych ani w klasycznych metodach nieliniowych. Szczególnie istotne jest to, że metoda działa deterministycznie, nie wymaga strojenia parametrów i jest odporna na małą liczebność próby, co czyni ją dobrze dopasowaną do realiów danych klinicznych.

Zastosowanie metody w praktyce klinicznej może wspierać diagnostykę różnicową, identyfikację podtypów chorób oraz monitorowanie zmian stanu pacjenta. Ponadto jej etapowy charakter umożliwia integrację danych pochodzących z różnych modalności, co otwiera drogę do bardziej zaawansowanych analiz w medycynie spersonalizowanej.

Podsumowując, zaproponowana metoda stanowi wartościowe i innowacyjne narzędzie analityczne, które może znaleźć szerokie zastosowanie w badaniach klinicznych oraz w systemach wspomagania decyzji medycznych. Jej dalszy rozwój, opisany w sekcji dotyczącej przyszłych kierunków badań, ma potencjał znacząco poszerzyć możliwości analizy danych wielowymiarowych w medycynie.

Abstract

This study presents a novel multi-stage, monotonic dimensionality reduction method designed for high-dimensional hematological data. The proposed approach reduces the original 18-dimensional feature space through a structured sequence of transformations ($18 \rightarrow 12 \rightarrow 6+2 \rightarrow 4$), enabling the preservation of both global and local data topology at each stage. Unlike classical techniques such as PCA, t-SNE, UMAP or autoencoders, the method maintains stable cluster structures across all intermediate spaces and allows controlled integration of additional dimensions without destabilizing the representation. The reduced 4-dimensional space reveals four clinically meaningful clusters corresponding to distinct hematological phenotypes: two subtypes of anemia and two subtypes of coagulation disorders. The method successfully separates these groups while retaining diagnostically relevant relationships between patients. Its deterministic nature, lack of hyperparameter tuning, and robustness to small sample sizes make it particularly suitable for clinical datasets. The results demonstrate that the proposed approach not only preserves essential diagnostic information but also uncovers hidden clinical substructures that are not detectable using conventional methods. This highlights its potential as a valuable analytical tool for differential diagnosis, patient stratification, and personalized medicine.